Physical Block V4 · ① 总览与 C 的形成

V4 设计稿 · 未实现

首帧 480×832 | 视频 81 帧 | Qwen 4096 → Wan 3072 | 原生文本独立保留

(a) 原生视频主干

zσ · 带跟视频 latent [B, 48, 21, 30, 52] → Conv3D patch embedding 48 → 3072 ; patch = (1,2,2) → [B,3072, 21, 15, 26] → flatten + transpose → **H** [B,8190, 3072] → 30 个原生 Wan blocks → 输出头 + unpatchify $\hat{v}$ [B, 48, 21, 30, 52]

第 3、6、…、30 层：**cross-attention 位置加入 Physical Block**，共 10 处；详见图④。

$P = 15 \times 26 = 390$； $T = 21$； $L = T \times P = 8190$；首帧 390 个位置。

(b) 首帧与文本进入 Qwen 的 4096 维证据空间

首帧 Io [B, 3, 480, 832] → 原生视觉编码 patch = 16 → [B, 1560, 1152] → 2 ×2 merge + 原生映射 4 × 1152 → 4096 → 视觉 tokens [B, 390, 4096]

原始请求 → 原生 tokenizer + embedding → 文本及特殊 tokens [B, N_t, 4096]

Qwen 原生多模态语言层 宽度 4096； 生成侧 LoRA 可训练 → **证据 H** [B, 390 + N_t, 4096]

保留原生 DeepStack / 位置编码；首帧网格坐标与有效 mask 随 H 保留。

(c) 主线：H 证据记忆 + Q latent reasoning

H [B, N_H, 4096] N_H = 390 + N_t

新 Q seed [B, 128, 4096]

Qwen 原生层 / prefix KV 读取 4096 → 4096

$Q^{(k)}$ [B, 128, 4096]

$k = 1 \cdots K$

全宽反馈适配 4096 → 4096

C ≡ R_hidden [B, 128, 4096] 场景相关条件与物理关系

H 路线：内容 hidden refinement [B, N_H, 4096] 同一后端，R 改为 NH

K 为推理轮数，待定； Q 槽不等于对象 ID；全路径保留梯度。

(d) C 在最终 Wan 接口投影；原生文本另一路进入

C [B, 128, 4096]

Wc_ℓ 4096 → 3072 → **K_cond** [B, 128, 3072]

Ws_ℓ 4096 → 3072 → **K_scope** [B, 128, 3072]

Wv_ℓ 4096 → 3072 → **V_rule** [B, 128, 3072]

每个注入层独立； K 的 norm 也独立； 进入图②③。

原始请求 → 原生 TS [B, 512, 4096] → Wan text embedding 4096 → 3072 → 3072 → **文本 context E** [B, 512, 3072] → 原生文本 attention； 见图④。

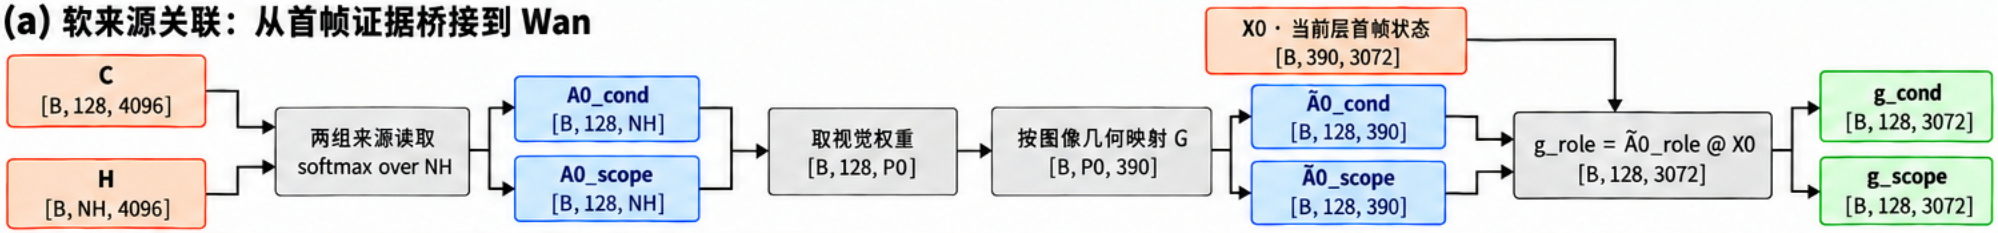
说明 B：batch；N_t：文本及特殊 token 数；R：关系槽数；ℓ：Wan 注入层。
C 的推理在 4096 完成，状态执行在 3072 完成。

Physical Block V4 · ② 首帧桥接与当前状态读取

V4 设计稿 · 未实现

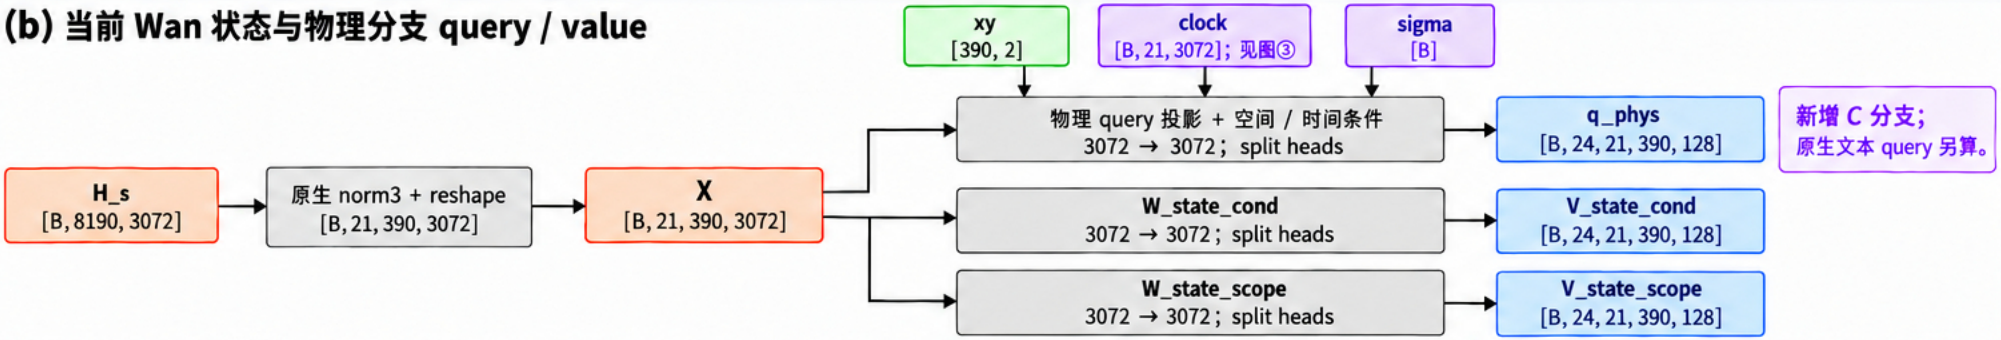
$R=128$，$T=21$，$P=390$ | $h=24$，$d=128$ | 每个注入层 ℓ 执行

(a) 软来源关联：从首帧证据桥接到 Wan

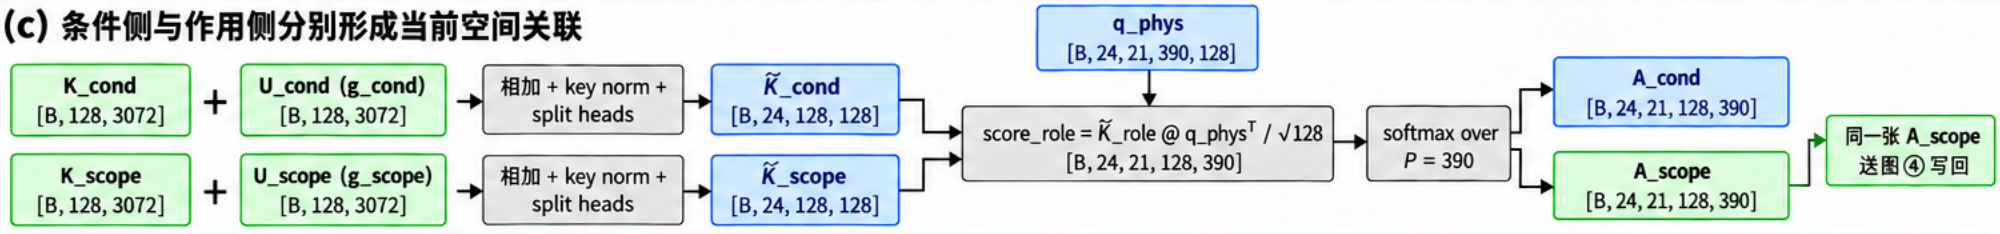


P0 = 390 为本例 Qwen 网格；G 来自裁剪 / 缩放几何；不等于物理区域标签。

(b) 当前 Wan 状态与物理分支 query / value



(c) 条件侧与作用侧分别形成当前空间关联



cond：条件证据；scope：受影响状态；每个时刻重新读取，允许区域重叠与变化。

(d) 读成全宽关系状态



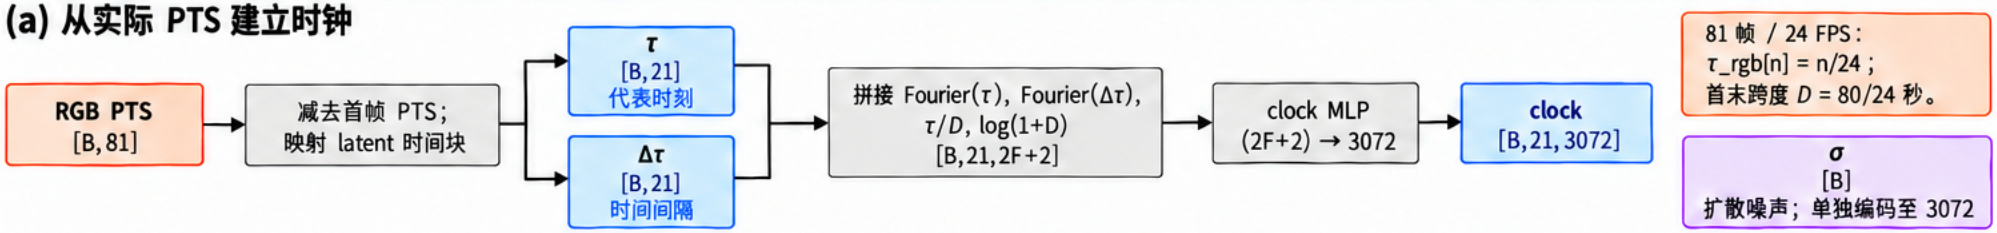
说明 g：首帧依据在当前 Wan 层的表示；u：当前视频时刻读取的状态；A：空间软关联，不是监督标签。两个 128 轴分别是关系数 R 与 head_dim d。

Physical Block V4 · ③ 物理交互与真实时间

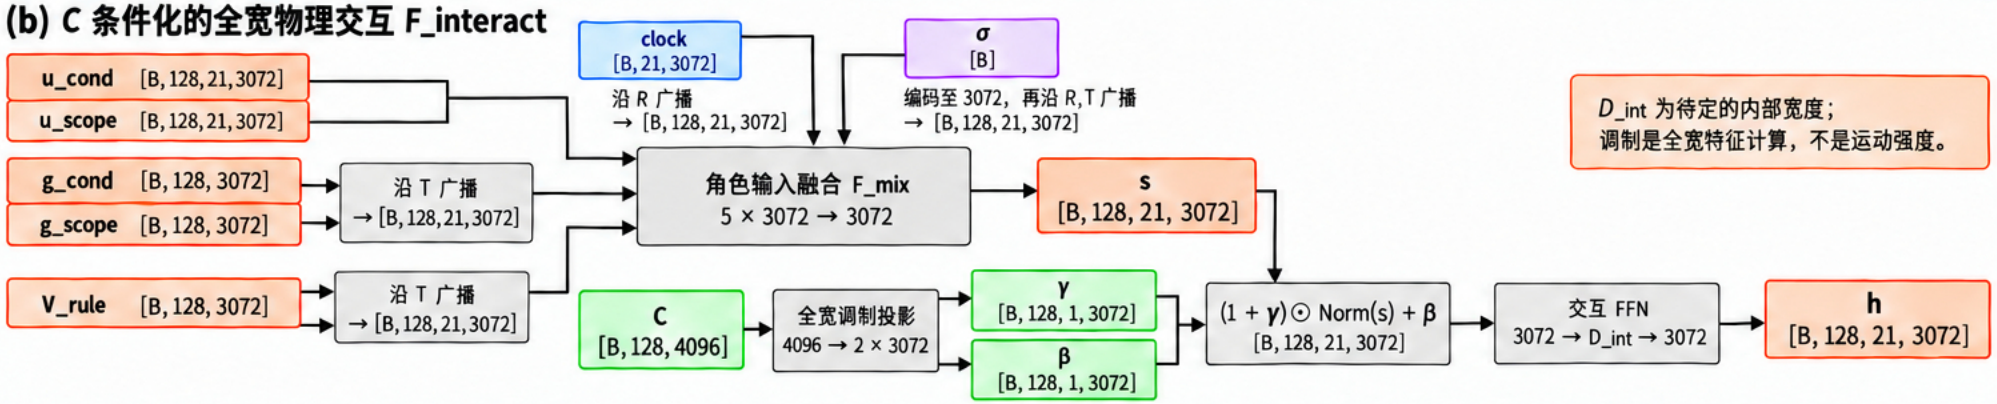
V4 设计稿 · 未实现

C 调节状态交互 | 关系状态 [B,128,21,3072] | 视频时间 τ 与扩散噪声 σ 分开

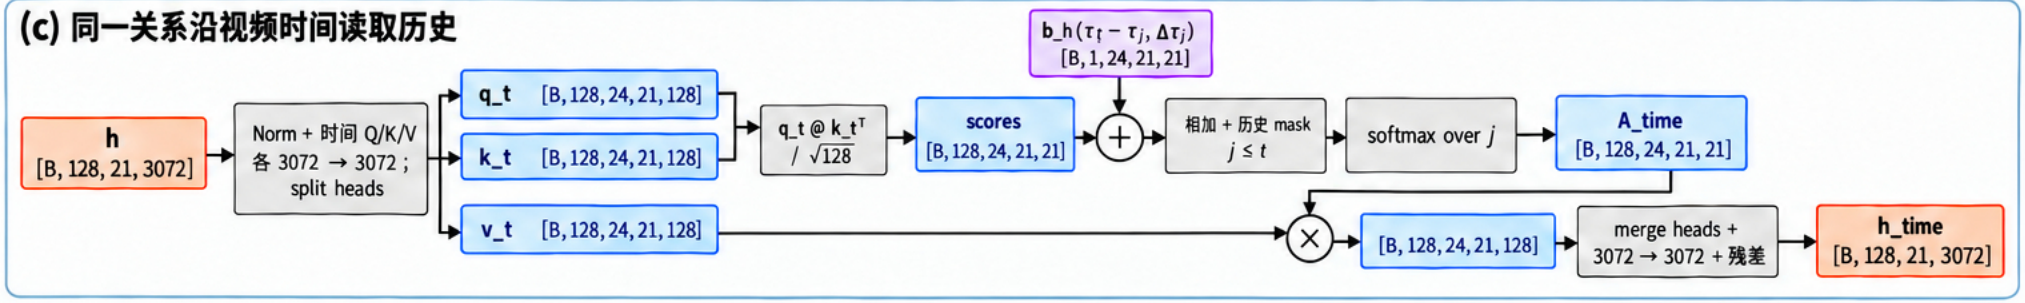
(a) 从实际 PTS 建立时钟



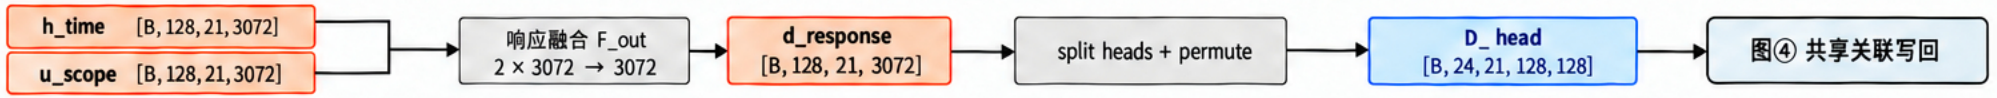
(b) C 条件化的全宽物理交互 F_interact



(c) 同一关系沿视频时间读取历史



(d) 生成待写回的响应



说明

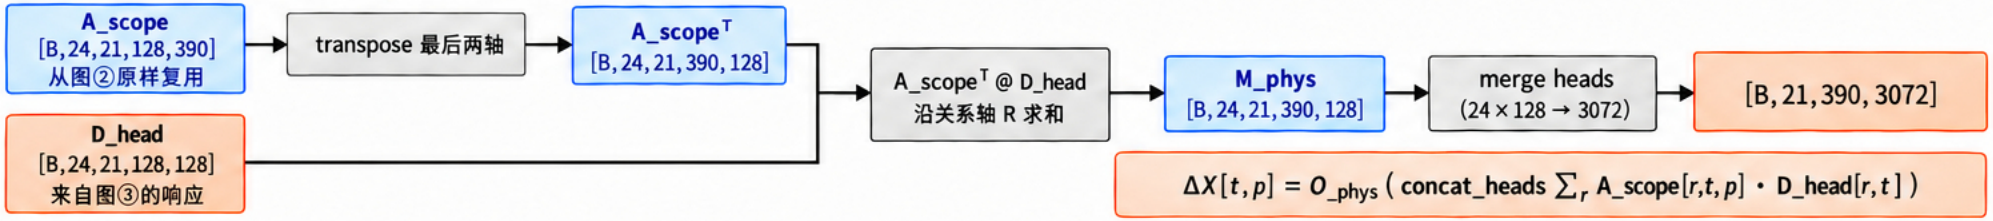
- F_mix / F_out 是待实现算子；图示为接口维度。
- *F* = 单组 Fourier 编码宽度； *D* = 片段时间跨度； *D*_int = 交互中间宽度。
- 原生 Wan 双向时序保持；
- 历史 mask 仅是新分支的顺序偏置。

Physical Block V4 · ④ 共享关联写回与原生 Wan 合流

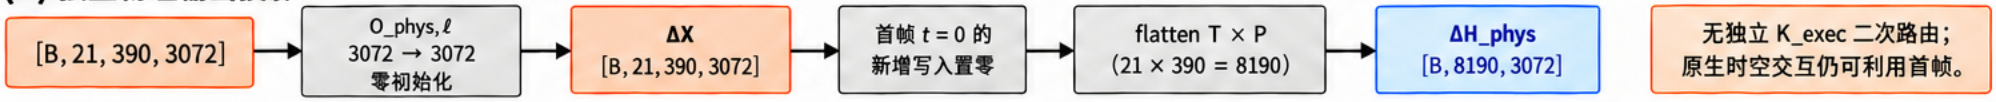
V4 设计稿 · 未实现

A_scope 同时用于读与写 | 文本与物理各自投影后相加 | 3072 = 24 × 128

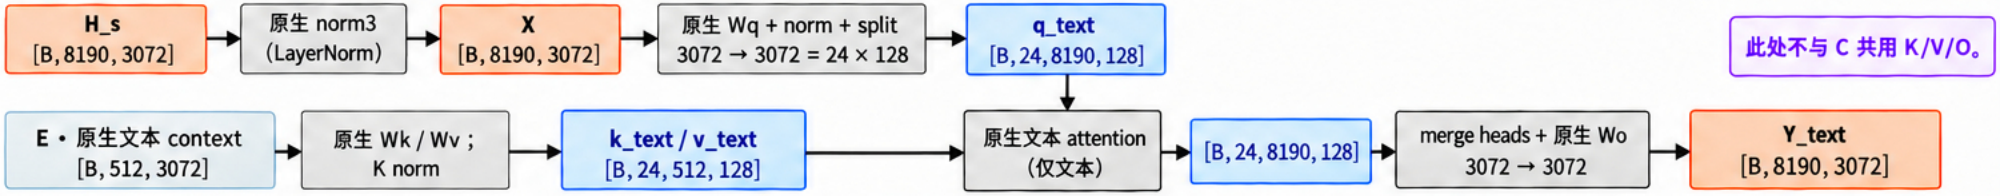
(a) 使用图②的同一 A_scope 写回；不重新计算位置路由



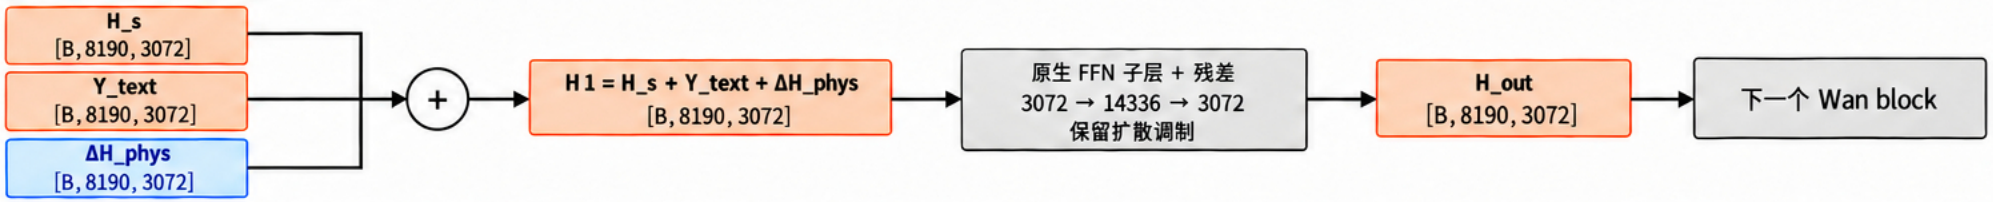
(b) 独立物理输出投影



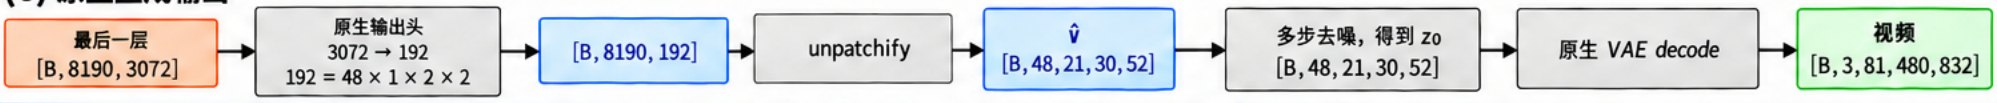
(c) 原生文本 attention 独立保留



(d) 合流后继续原生残差与 FFN



(e) 原生生成输出



说明

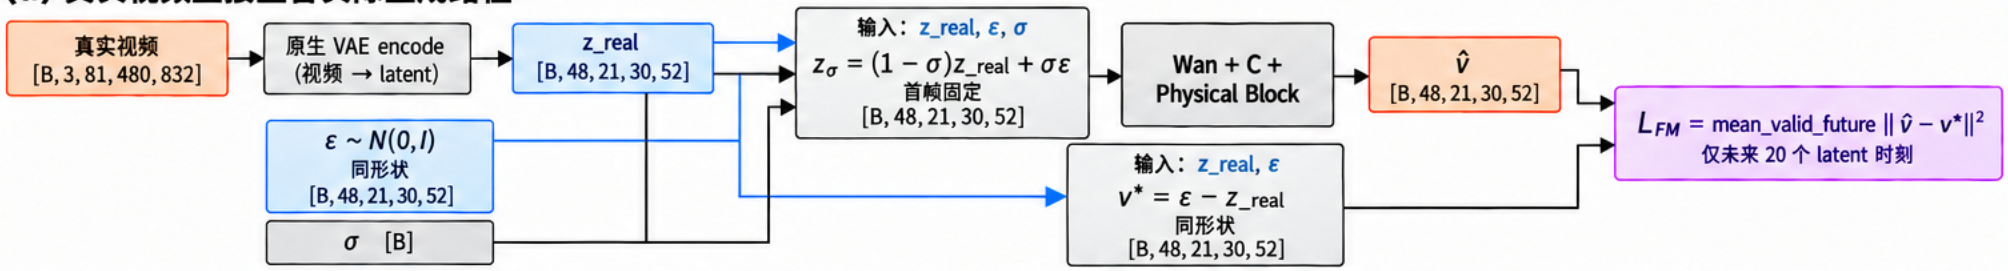
- ΔH_phys：新增物理残差；　Y_text：原生文本输出；　v̂：扩散流场，非物理运动速度。
- 两路输出分别投影，之后相加；首帧保持 12V 约定。

Physical Block V4 · ⑤ 两项损失与渐进训练

V4 设计稿 · 未实现

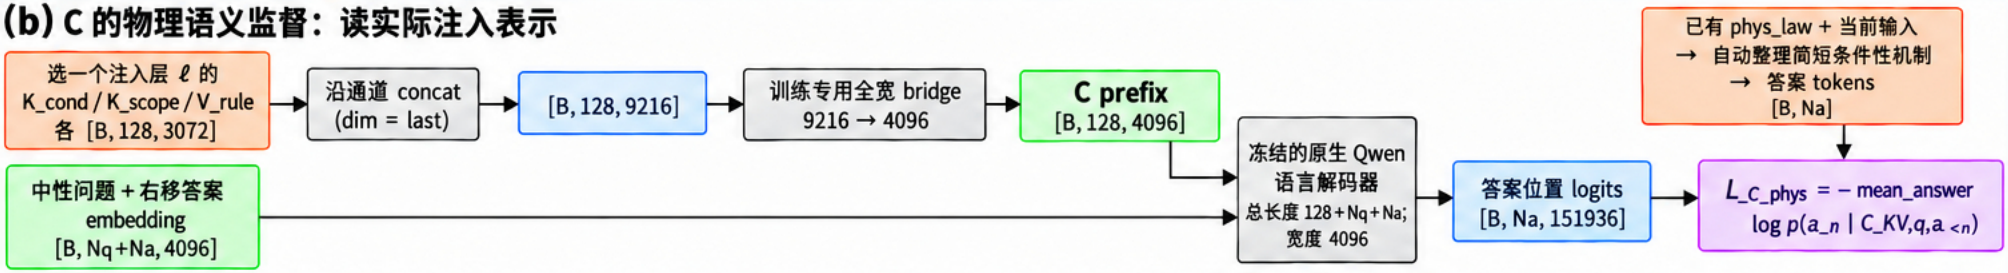
仅 L_FM + λ_phys L_C_phys | 无区域／事件补标 | 从官方基础模型开始

(a) 真实视频直接监督实际生成路径



FM → 实际写回 → 共享 A_scope → 交互／时间 → CK/V → Qwen

(b) C 的物理语义监督：读实际注入表示



原因／caption／H 不进入解码旁路；答案仅作训练目标

读出层 ℓ 按批轮换；该读出头推理时移除

(c) 总目标与数据职责

$$L_{total} = L_{FM} + \lambda_{phys} L_{C_phys}$$

FM：真实视频／已有 PTS；学习实际生成与时空执行

C_phys：已有物理文字的弱监督；学习条件性物理语义

不使用 temporal FM、source／scope／phase 损失； λ_phys 尚待配置

(d) 两个正式阶段，连续衔接

参数／目标	阶段 A · interface	阶段 B · joint
Qwen 生成侧 LoRA + Q/C	训练	继续训练
Physical Block + 独立 C K/V/O	训练	继续训练
C 语义 bridge	训练	继续训练
Wan self-attention 新 LoRA	冻结	学习率 0 → 目标值
官方基础权重／原生文本投影	冻结	冻结
L_FM + L_C_phys	始终参与	始终参与

接口 warmup → 连续保留 C／Physical Block 状态 → Wan LoRA 平滑加入

Na：答案长度；Nq：问题长度； 151936：Qwen 词表大小。冻结 Wan 参数不切断输入梯度。项目模块与 LoRA 新初始化；不加载旧实验 *CKPT*；无 *verifier*。